EV Challenge | GoodWe Brasil — Sprint 04

Relatório de evolução do assistente RAG

FIAP • Turma CCPH • Ciência da Computação, 2º semestre • 20 de outubro de 2026

Equipe

Victor Manzini (RM 572123); Guilherme de Oliveira Santos (RM 572195); Caio Marinho Pereira (RM 572873); Ricardo Tunes (RM 555919); Luiz Cesar Conti Salvador (RM 571305).

1. Objetivo e arquitetura

Evoluir o chatbot da etapa anterior para um assistente técnico GoodWe com recuperação aumentada por geração (RAG), respostas ancoradas em manuais, indicação de documento e página, interface Streamlit, comparações reprodutíveis e controles básicos de segurança.

Entrada	Processamento	Saída
Pergunta no Streamlit	Embeddings nomic-embed-text → busca ChromaDB → filtro de relevância/injeção → prompt v3 → Qwen 3 4B	Resposta técnica com fonte e página, ou recusa fundamentada

2. Configuração avaliada

Componente	Configuração
Modelo principal / comparativo	qwen3:4b-instruct / llama3.2:3b
Embeddings e índice	nomic-embed-text; ChromaDB persistente
Segmentação	800 caracteres; sobreposição 120
Recuperação final	top-k = 8; relevância mínima = 0,55
Geração	temperature = 0,2; top_p = 0,9; num_predict = 512
Interface	Streamlit; exibição de trechos, documentos e páginas

Base indexada informada durante os testes: 327 documentos de origem e 649 segmentos. Esses números são registros da execução local, não uma auditoria independente do conteúdo.

Resultados experimentais e evolução

3. Comparação controlada

Foram usadas as mesmas 10 perguntas: cinco técnicas (IDs 1, 5, 6, 7, 8) e cinco destinadas a testar recusas e bloqueios. A cobertura técnica mede quantas perguntas técnicas receberam resposta, não a precisão factual. A taxa de citação mede a presença explícita de nome do documento e página; não verifica automaticamente cada afirmação.

Configuração	Respostas técnicas	Citações explícitas
Qwen, prompt v2, limiar 0,60	4/5 (80%)	0/4 (0%)
Qwen, prompt v3, limiar 0,60	4/5 (80%)	4/4 (100%)
Qwen, prompt v3, limiar 0,55	5/5 (100%)	5/5 (100%)

4. Dois problemas resolvidos

Problema A — citações pouco rastreáveis. O prompt v2 frequentemente indicava apenas “Trecho 1” ou “Trecho 3”, sem identificar a fonte. Intervenção: prompt v3 com orientação explícita para citar nome do PDF e página. Efeito observado: citações explícitas passaram de 0/4 para 4/4 entre respostas técnicas geradas, mantendo o limiar 0,60.

Problema B — recuperação excessivamente restritiva. A pergunta sobre potências disponíveis foi recusada com limiar 0,60, embora o trecho relevante tivesse pontuação de aproximadamente 0,569. Intervenção: reduzir o limiar para 0,55, mantendo top-k 8. Efeito observado: cobertura técnica passou de 4/5 para 5/5. Esse ganho exige acompanhamento em perguntas fora do conjunto de avaliação, pois limiares menores podem introduzir ruído.

5. Comparação entre modelos

Também foi testado llama3.2:3b com prompt v2 e limiar 0,60: respondeu 4/5 perguntas técnicas, com 2/4 respostas contendo citação explícita. Em uma resposta, interpretou inadequadamente “CA” como “Carregador de Alta Potência”; o manual identifica a série como carregador de corrente alternada doméstico. O Qwen foi escolhido como configuração principal com base na avaliação local, sem generalizar para desempenho universal.

6. Avaliação manual: alcance e limites

Na configuração final, cinco respostas técnicas receberam notas manuais preliminares de faithfulness = 1,0 e answer relevancy = 1,0. As cinco recusas/bloqueios permaneceram fora dessas médias e devem ser relatadas separadamente. As notas não são RAGAS automatizado e dependem da verificação das afirmações frente aos trechos originais; em especial, a expansão da sigla RCD e as relações modelo–potência merecem revisão final.

Segurança, limitações e entrega

7. Controles de segurança testados

Duas tentativas de prompt injection enviadas diretamente como perguntas foram bloqueadas. Um teste adicional simulou um documento recuperado contendo instruções para ignorar regras, revelar o prompt e inventar informações. O filtro rejeitou o trecho; a saída foi status insufficient_context, sem fontes. O teste utilizou unittest.mock e não alterou o ChromaDB. Esses resultados cobrem apenas os padrões testados, não todos os ataques possíveis.

8. Evidência na interface

Na execução local do Streamlit, a pergunta “Quais são as potências nominais disponíveis na série GoodWe HCA?” retornou 7 kW, 11 kW e 22 kW, citando “GW_HCA Series_User Manual-PT.pdf, página 10”, e exibiu trechos recuperados das páginas 10 e 20. O modelo padrão foi alterado de gpt-oss:120b, indisponível localmente, para qwen3:4b-instruct. A interface foi validada ao iniciar com a variável OLLAMA_MODEL explicitamente configurada.

9. Limitações e próximos testes

O conjunto de dez casos é pequeno. As taxas de citação verificam formato, não correspondência semântica completa. A alteração do limiar requer testes adicionais de falsos positivos, documentos irrelevantes e outras formas de injeção. Para fortalecer a avaliação, revisar cada alegação frente às páginas citadas e pontuar as mesmas perguntas respondidas pelos diferentes modelos usando uma rubrica uniforme, sem tratar recusas como respostas factualmente fiéis.

10. Artefatos de apoio no repositório local

Código: src/rag/pipeline.py, src/rag/chunking.py, src/rag/vector_store.py, src/config.py, app/streamlit_app.py. Avaliação: evals/sprint4_eval_set.json, evals/resumo_comparativo_sprint4.json, evals/avaliacao_manual_sprint4.json e saídas por versão. Documentação: docs/relatorio_rag.md e docs/relatorio_modelos.md. O endereço público do GitHub não foi fornecido e deve ser incluído antes da submissão.

Conclusão

A Sprint 04 demonstrou evolução mensurável em rastreabilidade de fontes e cobertura das perguntas técnicas no conjunto de avaliação, mantendo recusas nos casos testados e introduzindo um teste controlado de injeção documental. Os resultados sustentam a escolha da configuração Qwen + prompt v3 + limiar 0,55 para a demonstração local, com as limitações metodológicas acima.