GoodWe ChargeAssistente — Evolução Sprint 04

FIAP · Turma CCPH · Ciência da Computação, 2º semestre

Victor Manzini (572123) · Guilherme de Oliveira Santos (572195) · Caio Marinho Pereira (572873) · Ricardo Tunes (555919) · Luiz Cesar Conti Salvador (571305)

1. Evolução da arquitetura

Sprint 03: chatbot conversacional com LangChain, memória e guardrails. **Sprint 04:** documentos GoodWe extraídos e segmentados, embeddings nomic-embed-text, ChromaDB persistente, busca com limiar de relevância, prompt com fundamentação documental e Streamlit exibindo fontes e páginas.

2. Configuração testada

Geração: Qwen3 4B Instruct (comparação: Llama 3.2 3B); temperatura 0.2; top_p 0.9; máximo 512 tokens. RAG: chunk 800 caracteres, overlap 120, k=8, limiar final 0.55, prompt v3. Avaliação: 10 perguntas fixas, sendo 5 técnicas.

3. Resultados observados

Configuração	Cobertura técnica	Citação explícita	Faithfulness*
Qwen v2, 0.60	4/5	0/4	0.75
Qwen v3, 0.60	4/5	4/4	0.75
Llama v2, 0.60	4/5	1/4	0.75
Qwen v3, 0.55	5/5	5/5	0.80

*Faithfulness: rubrica manual equivalente 0/0.5/1, média somente das respostas técnicas geradas. Answer relevancy média = 1.00 em todas as configurações, sobre as mesmas respostas. Não é RAGAS automatizado. A revisão integral do manual e dos fatos secundários permanece pendente.

4. Problemas, soluções e decisões

Citações ausentes: v2 indicava apenas “Trecho 1”; prompt v3 exigiu nome do documento e página, elevando citações explícitas de 0/4 a 4/4, sem demonstrar aumento de faithfulness nas mesmas quatro respostas.

Recuperação excessivamente restritiva: pergunta sobre potências tinha melhor score de aproximadamente 0.569; limiar 0.60 causava recusa. Ajuste a 0.55 elevou cobertura de 4/5 para 5/5; exige monitoramento de ruído.

Precisão técnica: Llama expandiu incorretamente “CA”; respostas de ambos os modelos expandiram “RCD” sem evidência auditada. A rubrica atribuiu 0.5 à faithfulness nessas respostas, evitando pontuação perfeita sem prova.

5. Segurança e limitações

Duas tentativas de injection direta foram bloqueadas; em teste isolado, um trecho documental malicioso simulado foi descartado com status insufficient_context e zero fontes. A evidência não garante robustez contra todos os ataques. O conjunto de 10 perguntas é pequeno; a contagem de citações mede presença textual, não correção de todas as alegações. Não há baseline RAGAS comparável das Sprints 1/2.

6. Evidências reproduzíveis

Arquivos: evals/qwen_v2_10.json, qwen_v3_10.json, llama_v2_10.json, qwen_v3_threshold055.json; evals/avaliacao_manual_comparativa_sprint4.json; docs/relatorio_rag.md; docs/relatorio_modelos.md; README.md. GitHub público e execução em máquina limpa devem ser verificados antes da entrega.